

扫描 PDF OCR 识别样例

一、扫描件基本信息

文件编号：SCAN-2026-0437。本文件模拟生产系统中上传的扫描件 OCR 结果，用于测试页眉页脚噪声、页码和低置信字段处理。

二、OCR 识别要求

扫描件进入知识库前，应完成图像纠偏、去黑边、OCR识别和置信度评估。涉及人名、地名、金额、日期、文号的字段需要额外规则校验。OCR 置信度低于 0.85 时，应进入人工复核。

三、重复页眉页脚

系统应去除重复页眉、页脚和页码噪声，但保留页码作为 citation metadata。