

# 扫描 PDF OCR 识别样例

## 一、OCR 识别质量要求

扫描件进入知识库前，应完成图像纠偏、去黑边、OCR 识别和置信度评估。低于阈值的字段不得直接参与自动著录。

## 二、页眉页脚噪声

本页模拟真实扫描 PDF 中常见的页眉、页码和重复标题。分块时应去除重复页眉页脚，但保留正文页码作为 citation metadata。

## 三、关键字段

涉及人名、地名、金额、日期、文号的字段，需要额外规则校验。OCR 置信度低于 0.85 时，应进入人工复核。